HealthSearch — Motor de Busca Híbrido com BM25 e Busca Semântica Vetorial

Gabriel Cavalcante Oliveira - Unipê - Ciência da computação

1. Problema e solução

Na HealthTech Solutions, médicos e enfermeiros buscam condutas em um repositório de protocolos. A busca puramente léxica falha com sinônimos (quem digita “ataque cardíaco” não acha o texto que diz “infarto agudo do miocárdio”), e a puramente vetorial dilui a precisão em códigos e siglas (CÓD-ECG-12D, AAS). Construímos o **HealthSearch**, um protótipo em Streamlit (arquivo único **healthsearch_app.py**) que roda os dois motores lado a lado e os une com **Reciprocal Rank Fusion (RRF)**, que dispensa normalizar scores de escalas diferentes, pois só usa as posições.

2. Arquitetura

Fase	O que foi implementado	Detalhes
1. Ingestão e pré-processamento	6 documentos fixos no código; **limpar_texto()** e **tokenizar()**	Minúsculas, remoção de acentos e caracteres especiais (CÓD-ECG-12D → cod, ecg, 12d) e stopwords em português. Indexamos título + conteúdo.
2. Motor léxico BM25	**busca_bm25()** com **rank_bm25.BM25Okapi**	Sliders na sidebar: $k_1 \in [0; 3]$ (padrão 1,2) e $b \in [0; 1]$ (padrão 0,75). O índice é reconstruído a cada mudança. Tratamos o NaN (0/0) que a biblioteca gera com $k_1 = 0$.
3. Motor semântico	**gerar_embeddings()** + **similaridade_cosseno()**	Modelo real *paraphrase-multilingual-MiniLM-L12-v2* (sentence-transformers). Se indisponível, cai numa **simulação vetorial documentada**: cada dimensão é um conceito médico (infarto, ECG, AVC...) e sinônimos ativam a mesma dimensão.
4. Fusão RRF	**fusao_rrf()**	Score = $\alpha/(60 + \text{Rank}_{BM25}) + (1 - \alpha)/(60 + \text{Rank}_{Sem})$, com $\alpha \in [0; 1]$ em slider e $k_{RRF} = 60$. Documento com score 0 num motor não foi recuperado e contribui com 0 (decisão explicada na seção 4).
Interface	**main()**	4 abas (Léxico, Semântico, Híbrido RRF, Matriz Comparativa), métricas de Top-1 por método, nº de docs com match léxico e tempo de busca, gráfico de contribuição de cada motor. Bônus: checkbox de re-ranking com Cross-Encoder (ms-marco-MiniLM-L-6-v2) no Top-3, mostrando a nota e a variação de posição.

3. Resultados: comparação de ranks

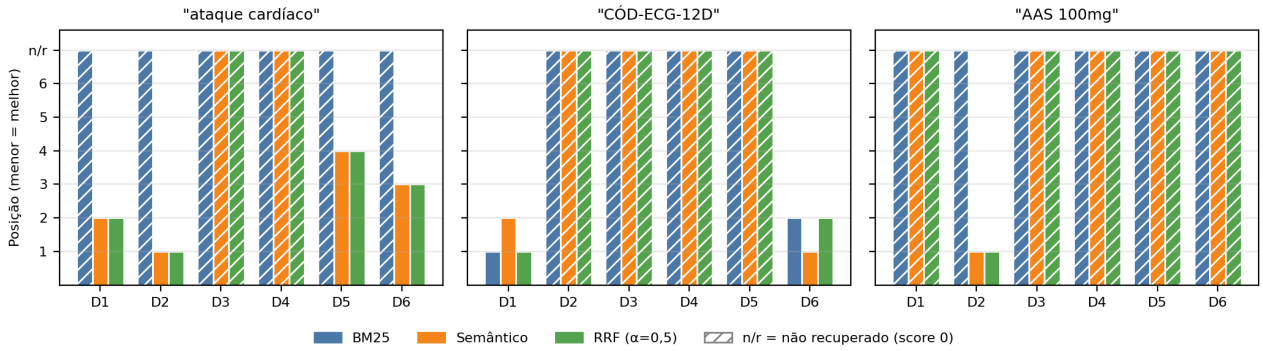


Figura 1 — Posição de cada documento por método ($k_1 = 1,2$; $b = 0,75$; $\alpha = 0,5$). Barras hachuradas: documento não recuperado.

Consulta	BM25	Semântico	RRF (α = 0,5)
ataque cardíaco	Nenhum documento recuperado (o texto diz “infarto”; “cardíaco” só aparece como “cardíaca”).	D2 (0,53) e D1 (0,41) no topo.	D2 em 1º: a cobertura semântica resolve o sinônimo.
CÓD-ECG-12D	D1 (1,90) e D6 (1,81), match exato do código.	D6 (0,85) e D1 (0,71); D2 a D5 ficam com score 0.	D1 e D6 no topo, D2 a D5 fora. Os scores empatam em 0,0163 e o desempate foi pela ordem do corpus.
AAS 100mg	Zero: o corpus escreve “ácido acetilsalicílico”, não “AAS”.	D2 (0,69), pelo sinônimo.	D2 em 1º.

4. Análise e decisões de projeto

Efeito dos parâmetros. Com $k_1 = 0$ o BM25 ignora a frequência do termo e o b deixa de ter efeito; para “CÓD-ECG-12D”, D1 e D6 empatam em 1,763. Com o padrão (1,2 / 0,75) o D1 passa à frente (1,899 contra 1,810). O α controla o desempate: $\alpha > 0,5$ favorece o D1 (léxico) e $\alpha < 0,5$ favorece o D6 (semântico).

Documentos não recuperados no RRF. Quando o BM25 zera tudo (“ataque cardíaco”), ordenar os empates pela posição no corpus dava pontos de RRF a documentos que o motor nunca encontrou. Corrigimos: só entra no ranking quem tem score > 0.

Limitações. (i) Os resultados acima foram gerados no *modo de simulação vetorial*, pois o ambiente de teste não tinha o modelo de embeddings; com o modelo real os scores mudam e devem ser regenerados. (ii) Sem stemming, “cardíaco” e “cardíaca” são termos diferentes para o BM25. (iii) O cross-encoder foi treinado em inglês, então a nota em português é apenas indicativa. (iv) Com só 6 documentos, o IDF do BM25 é instável (a biblioteca troca IDFs negativos por ε).

5. Divisão de tarefas

Integrante	Responsabilidades
[Nome do Aluno 1]	Fase 1 (corpus e pré-processamento), Fase 2 (BM25 e sliders) e testes das consultas.
[Nome do Aluno 2]	Fase 3 (embeddings, simulação e cosseno), Fase 4 (RRF) e bônus com Cross-Encoder.
[Nome do Aluno 3]	Interface Streamlit (abas, métricas, gráficos), relatório em PDF e revisão do código.